

DeepSeek 官方 API 调研报告

调研主题：DeepSeek 官方 API 的模型、上下文长度与价格 | 数据来源：DeepSeek 官方文档 (api-docs.deepseek.com) | 调研时间：2026-08

一、调研概述

本报告基于 DeepSeek 官方 API 文档《Models & Pricing》页面进行联网抓取与整理，汇总了当前官方开放 API 的模型名称、上下文长度、最大输出长度以及分时段的输入/输出定价，并附上使用成本方面的简要结论。所有价格均以「每 1M tokens」为单位计量。

二、模型与基本参数

当前 DeepSeek 官方 API 共提供 3 个模型（含 1 个视觉实验模型）：

- deepseek-v4-flash** — 通用对话/推理模型，支持思维模式与非思维模式，支持 FIM（非思维模式）等。
- deepseek-v4-pro** — 高阶专业模型，性能更强，支持思维模式与非思维模式，支持 FIM（非思维模式）。
- deepseek-v4-flash-vision-exp** — 视觉实验模型，可同时处理图片与文本，不支持 FIM。

三个模型均同时支持 OpenAI 兼容格式 (<https://api.deepseek.com>) 与 Anthropic 兼容格式 (<https://api.deepseek.com/anthropic>)，并支持 JSON 输出、工具调用、Responses API、Anthropic API 及 Chat Prefix (Beta) 等功能。

三、上下文长度与输出上限

项目	deepseek-v4-flash	deepseek-v4-pro	deepseek-v4-flash-vision-exp
上下文长度 (Context Length)	1M (百万)	1M (百万)	1M (百万)
最大输出 (Max Output)	最高 384K	最高 384K	最高 384K

并发上限 (Concurrency)	2500	500	2500
--------------------	------	-----	------

说明：三个模型上下文均为 1M（1,048,576）tokens，可支撑超长文档、长对话与整库检索等场景；最大一次性输出上限为 384K tokens。

四、价格明细（每 1M tokens，单位 USD）

DeepSeek 采用**高峰 / 低谷分时计价**：高峰时段为周一至周五 UTC 01:00–04:00 与 06:00–10:00，其余时间为低谷；**低谷价为高峰价的一半**。计费基于「Token 数 × 单价」，直接从余额扣费，若同时有赠送额度与充值余额，优先扣赠送额度。

模型	计费项	输入（缓存命中 CACHE HIT）		输入（缓存未命中 CACHE MISS）		输出（OUTPUT）	
		低谷	高峰	低谷	高峰	低谷	高峰
deepseek-v4-flash	单价	\$0.007	\$0.014	\$0.22	\$0.44	\$0.66	\$1.32
deepseek-v4-pro	单价	\$0.022	\$0.044	\$0.66	\$1.32	\$1.98	\$3.96
deepseek-v4-flash-vision-exp	单价	\$0.007	\$0.014	\$0.22	\$0.44	\$0.66	\$1.32

横向对比（均为低谷价）：

模型	输入·缓存命中	输入·缓存未命中	输出
flash / vision-exp	\$0.007	\$0.22	\$0.66
pro	\$0.022	\$0.66	\$1.98

注：图片发送至 deepseek-v4-flash-vision-exp 时，会按其尺寸折算为输入 token（连同文本 token 一起计费），具体转换规则见官方《Vision》文档。

五、调研结论

- 1. 模型梯度清晰。** DeepSeek 官方当前提供 V4 系列三条 API 产品线：Flash（高速通用）、Pro（专业高性能）与 Flash-Vision（视觉实验），三者共享 1M 超长上下文与 384K 最大输出，覆盖从轻量对话到多模态长文本的多种场景。
- 2. 定价策略分层明显。** 整套价格呈现「输出 > 输入未命中 > 输入命中」的梯度，配合高峰/低谷时段差异化计价（低谷为高峰一半），鼓励用户在非高峰时段调用以降低成本；同时缓存命中可实现近 30 ~ 60 倍的输入成本下降。
- 3. Pro 定位更高。** 无论输入命中、未命中还是输出，Pro 的价格基本是 Flash 的 3 倍（低谷 \$0.022 vs \$0.007 等），但其并发上限（500）低于 Flash（2500），更适合对性能要求高、调用量平稳的生产环境。
- 4. 成本估算参考。** 以 Flash 低谷价为例，输入缓存未命中 \$0.22 /1M、输出 \$0.66 /1M，即处理百万级 token 的输入+输出合计成本约为 \$0.88；总体而言 DeepSeek API 在同等上下文规模下具备较强的性价比。

本报告数据全部来自 DeepSeek 官方文档页面 (https://api-docs.deepseek.com/quick_start/pricing)，官网保留调整价格之权利，建议以官方页面最新信息为准。