

国内主流 LLM 厂商 API 价格调研分析报告

—— 市场格局 · 价格对比 · 成本测算 · 选型建议 ——

摘要

随着国内大模型进入商业化深水区，API 按量计价已成为企业级 AI 应用的基础成本单元。本报告针对国内主流大模型厂商（DeepSeek、阿里云通义千问、智谱 GLM、月之暗面 Kimi、字节跳动脉动豆包、百度文心、MiniMax 等）的 API 定价体系进行联网调研与横向对比，梳理各家的旗舰与经济档定价、计费规则、免费额度与优惠策略，并结合不同业务场景给出可落地的选型与成本优化建议。报告数据主要来源于各厂商 2026 年官方定价文档与开放平台，供技术决策与预算评估参考。

一、行业背景与市场格局

1.1 大模型 API 商业化进入“百模大战 + 价格战”阶段

2024 年以来，国内大模型 API 价格经历了多轮显著下调，“百万 Token 从千元级下探到个位数甚至角分级”。尤其是 2025—2026 年，随着 MoE（混合专家）架构、稀疏注意力、线性注意力、推理引擎优化与国产算力的成熟，长上下文推理的单位成本大幅下降，旗舰模型与经济型模型之间形成了清晰的“价格分层”。企业在选型时，已从单纯“选最强模型”转向“按任务匹配模型 + 控本”。

1.2 主要玩家与定位

当前国内具备规模化 API 服务能力的主流厂商可大致分为三类：（1）云厂商：通义千问（阿里云百炼），依托阿里云全栈能力，模型体系最全、生态最完善；（2）独立模型公司：DeepSeek（深度求索，以极致性价比与开源著称）、智谱 GLM（清华系，旗舰+Free 免费模型矩阵）、月之暗面 Kimi（长上下文与编程 Agent 见长）、MiniMax（多模态+长上下文）等；（3）互联网巨头：字节跳动豆包（火山方舟/火山引擎，主打低价与大规模应用）、百度文心（ERNIE，老牌中文搜索引擎背景）。

二、主流厂商 API 定价详表

厂商	代表性模型	上下文	输入(元/M)	输出(元/M)	备注
DeepSeek	V4-Flash	1M	3.0(高峰)	9.0(高峰)	空闲时段半价；缓存命中低至0.1元
DeepSeek	V4-Pro	1M	9.0(高峰)	27.0(高峰)	旗舰；空闲半价
阿里云	Qwen3-max	高	2.5(≤32K)	10.0	阶梯计费；新用户100万免费Token
阿里云	Qwen7-plus	256K/1M	2.0	8.0	Batch半价
阿里云	Qwen-plus	128K+	0.8	2.0	经济型；Batch半价
阿里云	Qwen-max(旧)	—	2.4	9.6	经典版
智谱	GLM-5.3	1M	约6.0	约20.0	旗舰，编程/Agent强
智谱	GLM-5.3-Flash	1M	约0.6	约2.0	原生多模态；约GLM-5.3的1/10

智谱	GLM-4.x-Flash	128K-200K	免费	免费	多款免费文本/视觉模型
月之暗面 Kimi	Kimi K3	1M	约5.0	约16.0	2.8万亿参数旗舰，长程编程
字节豆包	Doubao-Pro	128K+	约0.8	约2.0	火山方舟，主打低价
百度	ERNIE-4.0	128K	约0.5	约2.0	文心旗舰
MiniMax	MiniMax-M1	长	约1.0	约8.0	多模态旗舰

注：价格单位为人民币元/百万 Token，表格取自各厂商 2026 年官方定价（含高峰/标准档）。DeepSeek、阿里云通义千问为官网确认价格，其余厂商价格为主要档位市场公开口径，带“约”字为测算值，具体以各平台实时页面为准。输出价格通常显著贵于输入（约 3~4 倍）。

2.1 DeepSeek（深度求索）—— 极致性价比的“价格屠夫”

DeepSeek 凭借自研 MoE 训练框架、万卡智算集群与高效推理引擎，长期以低于行业数量级的价格提供接近一线能力的前沿模型。据官方定价文档，其 V4-Flash 高峰时段输入（缓存未命中）约 3 元/百万 Token、输出约 9 元；V4-Pro 输入约 9 元、输出约 27 元；非高峰时段（工作日 9:00-12:00、14:00-18:00 之外）一律半价；缓存命中输入可低至 0.05-0.1 元/百万 Token。1M 上下文、支持思考/非思考双模式，并兼容 OpenAI 与 Anthropic API 格式，迁移成本极低。

2.2 阿里云通义千问 —— 模型矩阵最全的一站式选择

阿里云百炼提供从旗舰 Qwen3.8-Max（输入约 12 元/百万、输出约 36 元）到经济型 Qwen-plus（输入 0.8 元、输出 2 元）的完整阶梯，并设置基于单次请求输入 Token 总量的“阶梯计费”（Token 越多单价越高），同时支持 Batch 调用半价与上下文缓存折扣。绝大多数千问模型为新用户提供 100 万 Token 免费额度（有效期 90 天），并依托阿里云生态，从文本、图像、视频、语音到向量检索全覆盖，是云原生企业的稳妥之选。

2.3 智谱 GLM —— 清华系，免费模型矩阵最丰富

智谱面向个人开发者打出“普惠牌”，不仅提供 GLM-5.3 旗舰（1M 上下文、编程/Agent 能力比肩 Claude），更推出了定价仅为旗舰约 1/10 的 GLM-5.3-Flash 原生多模态模型，以及多款完全免费的文本与视觉模型（GLM-4.7-Flash、GLM-4.5-Flash、GLM-4-Flash、GLM-4V-Flash 等），极为适合做原型验证、教学与低成本量产。其 GLM Coding Plan 订阅套餐还提供“积分制”额度，非高峰时段积分减半，性价比突出。

2.4 月之暗面 Kimi —— 长上下文与编程 Agent 旗舰

Kimi K3 为 2.8 万亿参数、1M Token 上下文旗舰，面向长程编程与端到端知识工作；Kimi K2.7 Code 为编程专用模型，支持 256K 上下文与多模态输入并提供高速档（highspeed）。Kimi 在“长文档 + Agent 场景”表现突出，常被用于 Claude Code、Codex 等编程工具链，定价位于中高端，但长上下文场景下的“性价比”突出。

2.5 字节豆包 / 百度文心 / MiniMax

火山引擎豆包（Doubao）以“低价 + 大规模应用”著称，Pro 级模型定价与通义经济型相当，适合高并发、对成本敏感的 To C 场景；百度文心 ERNIE 依托中文语料积累，旗舰 ERNIE-4.0 定价不高，适合中文搜索语义与知识类任务；MiniMax 在多模态（图像/视频/音频对话）与长上下文推理上特色鲜明，其 M1

系列在中文长文本任务上具备竞争力。

三、价格横向对比图




图 1 各厂商代表性模型 API 输入价格对比 (元/百万 Token)




图 2 各厂商代表性模型 API 输出价格对比 (元/百万 Token)




图 3 单次典型调用（输入 1M + 输出 2M Token）的估算总成本对比（元）

四、计费规则要点与成本优化策略

4.1 影响 API 实际成本的关键变量

- ① 输入 vs 输出单价严重不对称：绝大多数厂商输出单价为输入的 3~4 倍，因此应尽量让模型输出精炼、避免废话生成。
- ② 缓存大幅降本：系统提示词与长文档多次命中缓存时，输入价格可降低 90% 以上（如 DeepSeek 缓存命中仅约 0.05~0.1 元）。构造请求应充分复用稳定上下文。
- ③ 高峰/非高峰差异化定价：部分厂商（DeepSeek、智谱）对非高峰时段的调用给予半价优惠，可错峰运行批量任务。
- ④ 阶梯计费：阿里云等按单次输入 Token 总量分档，长 prompt 会导致整单上浮，需权衡上下文长度。
- ⑤ Batch 调用：支持异步批量调用的模型通常按实时价格半价计费（如千问系列）。
- ⑥ 免费额度 / 订阅套餐：新用户免费额度（如阿里 100 万 Token）、智谱免费 Flash 模型、GLM Coding Plan 积分制等，可显著拉低前期成本。

4.2 成本优化清单

- （1）优先使用缓存与稳定系统提示词；
- （2）对非实时、可容忍延迟的任务采用 Batch/异步调用；
- （3）高峰任务错峰到非高峰时段执行；
- （4）按任务复杂度分流——简单任务路由到经济版/免费模型，复杂推理才上旗舰；
- （5）用免费额度与体验券完成原型与 POC；
- （6）对长上下文需求，优先选择缓存/低价输入模型（DeepSeek、Kimi 等）；
- （7）监控每 1 元钱产出的 Token 数与业务转化，建立成本看板。

五、分场景选型建议

应用场景	推荐厂商/模型	核心理由
通用对话/客服/内容生成	通义 Qwen-plus、豆包 Doubao-Pro、智谱 GLM-5.3	经济型定价低，稳定成熟，量大控本
复杂推理/数据分析/智能体	DeepSeek V4-Pro、Kimi K3、GLM-5.3	旗舰推理强，Agent 长程任务表现佳
编程与代码生成 (IDE)	Kimi K2.7 Code、GLM-5.3/5.3-Flash、DeepSeek	深度适配 Claude Code/Codex 等工具
长文档/百万级上下文	DeepSeek、Kimi K3、GLM-5.3 (1M 上下文)	长上下文 + 缓存降本
中文语义/搜索/知识问答	百度文心 ERNIE、通义千问	中文语料与搜索生态优势
教学/原型/低成本量产	智谱 GLM Flash 系列 (免费)、DeepSeek	免费或极低，上手门槛低
多模态 (图/视频/语音)	通义千问、MiniMax、豆包	全模态覆盖，场景化解决方案
高并发 To C 大规模应用	字节豆包、通义 Qwen-plus	低价 + 高吞吐 + 生态基建

六、综合建议

1. 多模型策略是主流。单一厂商很难在所有维度（成本、推理、长上下文、多模态）同时最优，建议采用“路由网关”按任务复杂度与经济性自动分流，实现效果与成本的平衡。2. 成本敏感业务优先看“输出单价 × 输出量”。输出最贵，先把 prompt 与输出长度约束做扎实，再谈选型。3. 重推理 / 长文档场景，DeepSeek 与 Kimi 的“缓存 + 非高峰半价”是最省钱的路径。4. 熟悉云的团队优先选阿里云百炼，模型矩阵最全、Batch/缓存/阶梯规则透明，且与云资源天然打通。5. 原型与轻量产品从免费/低价模型起步（智谱 Flash、通义 Qwen-plus、DeepSeek），指标达标后再升级。6. 持续跟踪价格变动。国内大模型价格仍在快速下行，建议每季度复核一次，及时切换更优档位。

声明：本报告数据来源于各厂商 2026 年公开官方定价与开放文档（含 DeepSeek API 文档、阿里云百炼计费文档、智谱 BigModel 文档、Moonshot Kimi 开放平台、火山引擎火山方舟等）。部分厂商价格页为动态渲染，报告中的少数价格采用市场公开口径测算，最终以各平台实时控制台与对账单为准。本报告仅供选型与预算评估参考，不构成任何投资或商务承诺。